

# Parameter Efficient Transfer-Learning for NLP <paper>

## <abstract>

fine-tuning은 다른 task의 task가 들어올때마다 기존 parameter/model 재학습(가)야 함. 이 대신 **adapter module**을 활용한 transfer를 제안.  
기존의 fine-tuning은 모델의 parameter를 그대로 두어 공유하고, 새로운 task를 추가함

## <Intro>

BERT: large text corpora로 BERT loss와 함께 학습된 Transformer Network. (Text classification / QA)  
특히 BERT는 다양한 task를 수행할 수 있는 general application을 얻었음.  $\rightarrow$  Compact / Extensible downstream Model

- ① Compact: 각 task에 적은 파라미터의 추가(반으로 많은 task로 fine-tuning)
- ② Extensible: 전의 task와 같이 많은 새로운 task로 fine-tuning

이전의 fine-tuning은 feature-based transfer learning을 사용. 여기서 adapter module은 새로 제안함.  
 $\hookrightarrow$  사전 학습된 real-vecord embedding vector를 사용.  
 $\hookrightarrow$  사전 학습된 Network에서 weights를 copy, down-sampling 및 배치 정규화.  
 $\Rightarrow$  각 task마다 다른 weight set이 필요함. 하지만 fine-tuning한 adapter는 두 task가 공유하는 parameter를 비슷한 성능 보임.

Adapter? : 사전 학습된 네트워크의 층 사이에 추가하는 새로운 모듈. blue model + adapter module

① **Stronger** against Feature-based / Fine-tuning.

function with parameters.  

$$\psi_w(x) \begin{cases} \text{FB} : \chi_v(\phi_w(x)) - \text{M3은 함수 } \chi, \text{ V만 학습.} \\ \text{FT} : \text{Comparability를 저장하여 각 task에 } w \text{를 조정.} \\ \text{AT} : \psi_{w,v}(x), \text{ 새로운 함수 } \psi, w \text{는 copy, } \chi \text{와 } v \text{는 } \psi_{w,v}(x) \sim \phi_w(x) \text{에서 } v \text{만 fine-tuning.} \end{cases}$$
 $\hookrightarrow w$ 는 pre-training task의 pre-training에 영향 주지 않음. 보통 기존 network  $\phi_w$ 이 새로운 레이어를 추가하는 방식. (param)

② **Robust** against Multitask / Continual

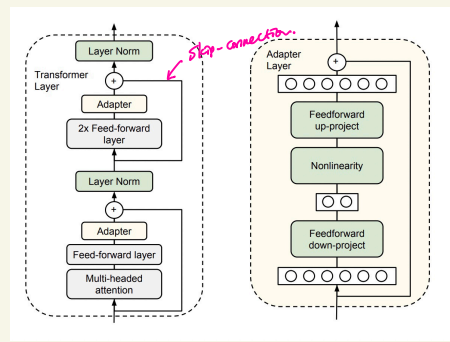
Multi-task Learning: 모든 task에 동시적인 학습 요구  $\Rightarrow$  AT는 좋음.  
Continual Learning: 끊임없는 task 처리, 하지만 재학습 시에는 전의 task를 잊어버림.  
 $\Rightarrow$  반면 AT는 공유된 parameter에 대해 조정하기 때문에 잊어버리게 전 task를 기억함.

## <Adapter tuning for NLP>

Goal: ① 좋은 성능. ② 레이어의 복잡성이나 연산 횟수 감소 ③ 각 task에 적은 수의 파라미터만 추가함

Deep network의 vanilla fine-tuning에서는 네트워크의 각 layer의 weight를 수정 가능. 이는 upstream과 downstream task의 label space와 loss가 다를 때 문제가 발생함.  
하지만 Adapter tuning에서는 가장 뒤의 layer를 하나 더 추가하고 이 layer의 parameter를 bottleneck으로 조정해서 fine-tuning.  
이는 task가 추가되면 동 model size의 증가를 줄여줌, Near-Identity initialization을 Adapter에 적용하여 기존의 network에 영향을 주지 않고 좋은 성능의 학습을 가능.  
 $\hookrightarrow$  layer 하나씩만 추가.  
 $\hookrightarrow$  그 layer에 적은 수의 param 추가. 기존에 있던, 특정 layer를 대체.

## <Instantiation for Transformer Networks>



- Feed forward와 Attention layer 모두 projection을 통해 input output size를 맞춤.
- Both use skip-connection (or FC) / 임의의 pre-training을 위해 사용  $\rightarrow$  Normalization
- 각 sub-layer 뒤에 adapter를 적용하는 구조 (projection 후, skip-connection 전), 2번의 Normalization이 들어감.
- parameter를 효율적으로 사용하기 위해 **bottleneck architecture** 제안. (특정 layer, 특정 layer)
  - $d$ -dim의 feature를 더 작은 dim의 bottleneck으로 project. (bottleneck dimension)
  - 각 레이어는 bias를 포함하여  $2nd + d \times m$  양의 parameter가 추가됨.
  - 편향으로 가는 2개의 파라미터의 0.5% ~ 0.7% 정도를 사용.
  - Adapter는 skip-connection을 이어 포함.
  - projection layer의 파라미터가 이미 pre-training 시에 초기화되면, module은 거의 Identity-function으로 초기화됨.
- 각 task마다 new layer normalization parameter를 학습. (Conditional batch normalization과 비슷).
  - 각 레이어마다 2d 인출의 parameter가 추가됨.

## <Experiments>

GLUE를 포함, 다양한 레이어에 적용  
 Adam 최적화  
 Pre-trained BERT Transformer network (24 layer, 390M param)  $\hookrightarrow$  ex) FT: 9%, AT: 1.3%  
 $\rightarrow$  classification task에 있어 좋은 성능은 fine-tuning이지만 적은 parameter만으로 적은 성능차이를 의미함.